

분산 시스템과 장시간 비동기 작업이 많은 AI/3D 도메인에서 런칭, 안정화, 수익화를 맡아온 백엔드 엔지니어입니다. 제한된 리소스에서도 글로벌 AI 서비스 런칭, 장시간 작업 운영 표준화, 3D 자동화 파이프라인 구축으로 서비스 안정성을 높이고 비즈니스 성장에 기여했으며, 3D 자동화·AI 고도화 등의 성과로 사내 엔지니어링·AI 부문에서 여러 차례 수상했습니다. 비동기 워커 기반 운영 모델, 오토스케일링, 장애 격리 설계를 여러 서비스에 걸쳐 재사용 가능한 패턴으로 정착시켰습니다. 필요할 때는 FE/ML/인프라 협업 병목도 직접 메우되, 중심은 항상 안정적인 백엔드 운영 모델과 도메인 설계에 두고 일해왔습니다. 최근에는 다양한 인터리어 에이전트를 오케스트레이션하는 AI Agent Platform을 설계·구축하고 있습니다.

📄 경력 사항

Bucketplace (오늘의집)

📅 2022년 8월 - 현재

Senior Backend Engineer

- **Ohouse AI 런칭**: 6주 목표를 **4주로 앞당겨 170개국** 글로벌 런칭을 완료했습니다. 사용자 요청 API와 장시간 AI 작업을 분리하도록 메시지 큐 기반 워커와 오토스케일링, 실패 격리, 상태 관리·재시도 패턴을 설계해 예측 불가 트래픽을 안정적으로 처리했습니다.
- **Ohouse AI 수익화/고도화**: Apple/Google IAP 라이프사이클을 하나의 상태머신으로 추상화해 구독 시스템을 신규 구축하고, 상태 전이 기반 검증으로 결제 정합성을 확보하며 매출 기반을 마련했습니다.
 - Amazon Affiliate 정책 제약을 반영한 RAG 기반 제휴 추천을 설계해 **CVR 10.5%**로 수익화를 검증했고, **LLM Provider Fallback + Circuit Breaker**를 적용해 특정 LLM provider 장애 시에도 서비스가 지속되도록 구성했습니다.
 - Spring 기반 LLM 프레임워크의 한계로 Python으로 전환하고, **Langgraph 기반 graph 구조**로 재설계해 AI 워크플로우를 유연하게 확장할 수 있게 했습니다.
- **Panorama AR**: 사용자의 실제 방을 3D로 재구성해 가구를 배치해볼 수 있는 서비스의 백엔드를 리드했습니다. MLE 연구 결과를 서비스로 연동하는 마이크로서비스를 설계·런칭하고, 비동기 상태관리로 장시간 3D Reconstruction 파이프라인을 안정적으로 운영하며 일 **~300건** 룸 스캔을 처리했습니다.
- **Room Planner**: 성능·안정성 개선으로 **WAU 704% 성장**과 **연간 GMV 600%(8.6억)**에 기여했고, **10.2배 트래픽**에서도 **99.95% 가용성**을 유지했습니다.
 - API **200ms→80ms**, payload **54%** 절감, **모바일에서도 무거운 3D 씬을 안정적으로 처리할 수 있도록 LoD 자동 생성**으로 3D 모델 **90%** 경량화. Draw call **3,000→20(99%)**, 모델 로딩 **10초→2.5초**로 모바일 렌더링 병목을 해소했습니다.
 - 부하 테스트로 이벤트/챌린지 스파이크를 사전 검증해 **무사건으로 운영**했습니다. AR Size Box로 AR 지원 상품을 **2,210→231,000개(104배)** 확대해 구매 전환율 **1.7배** 향상에 기여했습니다.
 - 연관 상품 추천을 실시간 스코어링에서 **오프라인 스코어링 알고리즘으로 재설계**해 검색 API 레이턴시를 **99.7%** 절감했습니다.
- **3D 에셋 자동화**: 수작업 3D 제작 파이프라인을 자동화해 월 생산량 **68개→800개**, 비용 **88% 절감**으로 **Eng Award**를 받았습니다.
 - 에셋 관리 시스템(DAM) 구축으로 GPU **20%** 감소, 파일 크기 **51%** 축소, **연간 40일+** 운영 시간 절감(**Top Contributor**). GPT-4o 기반 12개 기준 품질 선별로 E2E 자동화를 완성했습니다.
- **기술 리더십**: 신규 입사자·FE/ML 인원을 **온보딩**과 **코드 리뷰**로 백엔드에 독립 기여할 수 있도록 이끌었습니다.
 - 릴리즈 노트·데이터 분석 자동화로 팀 배포 주기를 단축해 **AI Award, AI Native MVP**를 받았습니다.

LG CNS

📅 2020년 1월 - 2022년 7월

System & Solution Programming Consultant

- Node.js · Redis 기반 실시간 싱크 서버를 설계·운영하고, WebSocket 기반 다중 사용자 동시 편집 환경을 구축했습니다.
- GitLab/Jenkins 기반 CI/CD 파이프라인을 자동화해 빌드·테스트·배포 리드타임을 단축하고, Unity 클라이언트와 연동되는 백엔드 API를 개발했습니다.

🎓 학력 사항

서울시립대학교 | 석사, 컴퓨터과학 | 인공지능 시스템의 성능 개선 연구 / 학·석사 연계 프로그램을 통해 석사 학위 조기 취득

📅 2018년 - 2019년

서울시립대학교 | 학사, 컴퓨터과학부

📅 2012년 - 2017년

Ohouse AI 런칭 및 고도화

문제

실제 인테리어 사진에 가구를 자동 배치하는 AI 서비스를, 제한된 리소스와 여러 팀 의존성이 얽힌 상황에서 6주 안에 글로벌 런칭해야 했습니다. 멀티턴 이미지 생성 특성상 사용자별 요청 순서 보장과 쿼터 제한 대응이 필수였고, 외부 AI 장애 전파도 차단해야 했습니다.

접근

메시지 큐 기반 비동기 워커로 API와 처리를 분리하고, Kubernetes 오토스케일링과 동시성 제한으로 독립 운영했습니다. 재시도·격리 정책을 설계하고, 인증 서버 준비 지연을 JWT 기반 게스트 인증으로 우회해 런칭을 앞당겼습니다. 런칭 후에는 Apple/Google IAP 상태머신과 LLM Provider Fallback + Circuit Breaker, AI provider 전환 구조를 적용하고, Spring LLM 프레임워크 한계로 Python 전환 후 graph-based 구조로 재설계해 수익화와 확장이 가능하게 했습니다. Amazon Affiliate 정책 제약을 반영한 RAG 기반 추천 경로를 설계해 실시간 제휴 상품 추천을 제공했습니다.

결과

4주 만에 170개국 런칭을 완료하고, 오토스케일링과 백프레서로 예측 불가 트래픽에서도 장애 없이 운영했습니다. AI provider 전환 가능한 연동 구조로 외부 장애에서 빠르게 복구했고, 제휴 상품 **CVR 10.5%**로 수익 모델을 검증했습니다.

3D 에셋 파이프라인 구축 및 생산 자동화

문제

Room Planner와 AR 기능에 필요한 3D 모델을 수작업으로 제작하고 있었습니다. 기존 에셋은 관리 체계 없이 GPU와 스토리지를 비효율적으로 사용했고, 신규 모델은 처리량과 품질 편차로 상품 확대를 감당하기 어려웠습니다.

접근

에셋 관리 시스템(DAM)을 구축해 중복 제거·자동 최적화·배포 파이프라인을 체계화하고, 운영 대시보드에서 3D 프리뷰·AR/Room Planner 연동 검수까지 엔지니어 의존 없이 처리할 수 있도록 했습니다. Image-to-3D 파이프라인은 상태 흐름 기반으로 자동화하고, 워커별 진행도를 DB로 관리해 장애 복구와 수평 확장이 가능하도록 했습니다. 반복 실험으로 파라미터를 고정하고 fallback 로직으로 예외 케이스를 처리해 품질 편차를 줄였으며, GPT-4o 기반 12개 기준 품질 선별로 E2E 자동화를 완성했습니다.

결과

DAM 구축으로 GPU **20%** 감소, 파일 크기 **51%** 축소, **연간 40일+** 운영 시간 절감으로 **Top Contributor**에 선정되었습니다. Image-to-3D 자동화로 월 생산량 **68개→800개**, 비용 **88% 절감**, **45개 신규 카테고리** 확장을 이뤄 **Eng Award**를 받았습니다.

Room Planner 성능 안정성 강화

문제

모바일 3D 인테리어 배치 서비스에서 초기 로딩 지연이 사용자 이탈과 성장 정체의 핵심 병목이었습니다. 이벤트/챌린지 트래픽 스파이크에서도 무중단 운영이 필요했고, 렌더링이 느려 사용자 체류 시간이 짧은 것도 문제였습니다.

접근

성능: LoD 자동 생성과 Mesh Simplification으로 3D 모델을 **90% 경량화**하고, API 호출 구조 개선으로 지연을 **200ms→80ms**로 단축했습니다. Draw call **3,000→20**과 렌더링 파이프라인 개선으로 정적 렌더링 **60초→20초**, 애니메이션 **20분→3분**을 달성했습니다. **안정성:** 큐 기반 지표 모니터링과 안전한 종료 규칙으로 스케일링을 안정시키고, 부하 테스트로 이벤트/챌린지 스파이크 시나리오를 사전 검증했습니다.

결과

성능 개선으로 사용자 세션 시간이 **21분→35분(68%)**으로 증가하며 **WAU 704% 성장**, **연간 GMV 600%(8.6억)** 성장에 기여했습니다. 이벤트/챌린지 트래픽 급증 구간에서 **무사건으로 운영**하며 **10.2배 트래픽**에서 **99.95% 가용성**을 유지했습니다.